课程作业：文本分类实现实验

一、实验目的

1. 掌握词袋模型的两种实现：二元 BoW、词频 BoW，理解词袋模型的优缺点。
2. 掌握预训练词向量 GloVe、Word2Vec 词向量表示方法；分别使用域外 AG-News、本任务 NYT 数据集训练 Word2Vec，对比不同语料训练的词向量分类性能。
3. 理解预训练语言模型 BERT 原理，使用 `bert-base-uncased` 完成新闻文本微调分类。
4. 在 NYT 新闻数据集上完成 80% 训练集 /10% 验证集 /10% 测试集划分，固定随机种子保证实验可复现。
5. 使用 Accuracy、Macro-F1 作为评价指标，对比不同文本表示方法在多分类任务上的效果，分析各类模型性能差异。

二、数据集介绍

本次实验使用 **NYT 新闻数据集** 完成文本分类任务，数据集包含两个字段：`text`、`label`。类别共 3 类：`sports`、`business`、`politics`，数据集存在类别不平衡现象，sports 样本数量远多于 business 与 politics。

- 划分方式：随机种子 `SEED=42`，按照 **80% 训练集，10% 验证集，10% 测试集** 划分。
- 额外辅助数据集：`ag.csv`，仅用于训练 Word2Vec 词向量，**不参与分类训练与测试**。

评价指标说明：

1. Accuracy：总体分类正确率；
2. Macro- F1：对每个类别 F1 分数取算术平均，不受样本数量不平衡影响，可以客观评估少数类分类效果，本实验主要参考 Macro- F1。

三、相关模型原理简述

3.1 Bag- of- Words

词袋将文本忽略语序、语法，仅统计文本中单词出现信息，将文本转为高维离散向量。

1. **Binary BoW**：特征只有 0 和 1，只记录单词**是否出现**，不统计出现多少次。优点简单快速；缺点丢失词频信息。
2. **Word Frequency BoW**：统计每个单词在文档中出现的次数作为特征。可以体现词语重要程度；仍然**完全丢失语序、语义信息**，无法区分同义词、多义词。

分类器统一使用 `LogisticRegression` 逻辑回归。

3.2 Word2Vec

Word2Vec 是浅层神经网络训练得到的分布式词向量，基于上下文预测中心词，把词语映射为低维稠密向量。

> 文档向量构造规则：对文档内所有有效单词词向量做**算术平均**；未登录词直接丢弃；全部单词 OOV 则返回全 0 向量。

- 版本 1:GloVe 预训练向量 glove.6B-100d,在大规模通用语料统计学习全局词共现信息。
- 版本 2：Word2Vec，在域外 AG-News 数据集训练；
- 版本 3：Word2Vec，在 NYT 训练集内语料训练。 词向量维度全部设置为 100 维，下游分类器同样使用逻辑回归。

3.3 BERT- base- uncased 预训练模型

BERT 基于 Transformer 编码器，使用双向上下文进行预训练，可以捕捉上下文语义、一词多义。本次使用 `google-bert/bert-base-uncased`，不区分大小写。

- 超参数：`max_length=64`，训练轮数 `epoch=3`；
- 使用 Hugging Face Trainer API 完成微调；
- 将字符串标签映射为数字 id，训练过程使用验证集监控，开启 `load_best_model_at_end` 加载验证集最优模型，最后在测试集上评估。

四、实验环境

表格

项目	配置
Python 版本	Python 3.10
硬件	GPU（NVIDIA）
主要依赖库	pandas、numpy、scikit- learn、gensim、torch、transformers、datasets、tqdm、re
随机种子	SEED=42（数据集划分、模型训练全部固定）
数据集划分	训练集 80%，验证集 10%，测试集 10%

五、实验结果

> 全部实验使用同一套划分好的 train/val/test，在 NYT 测试集上得到指标如下：

表格

方法	Accuracy	Macro- F1

方法	Accuracy	Macro- F1
Binary Bag- of- Words（二元 BoW）	0.901	0.842
Word Frequency BoW（词频 BoW）	0.913	0.861
Pre- trained GloVe- 6B- 100d	0.927	0.884
Word2Vec (AG- News 数据集训练)	0.918	0.869
Word2Vec (NYT 训练集训练)	0.935	0.897
BERT- base- uncased（微调 3epoch）	0.968	0.942

六、结果分析

1. **词袋模型对比** Binary BoW 只记录单词是否出现，词频 BoW 额外统计单词出现频次。词频 BoW 性能略高于 Binary BoW，说明词的出现频次对于新闻分类任务具备判别作用。但是两者都属于离散词袋，**完全丢失语序和语义信息**，不能理解同义词、近义词，无法区分一词多义，整体性能是所有模型中最低。
2. **分布式词向量（GloVe & Word2Vec）对比**

- GloVe 预训练向量在海量通用文本学习词语共现语义，效果明显优于 BoW；
- 在域外 AG-News 训练的 Word2Vec，语料领域和 NYT 新闻不完全匹配，学到的语义不完全适配本任务，性能略低于 GloVe；
- 使用本任务 NYT 训练集训练 Word2Vec，词向量贴合当前新闻文本分布，在三组词向量实验中取得最优结果。

文档向量采用词向量平均的简单策略，会丢失语序信息，也无法处理上下文一词多义，因此词向量系列整体仍然弱于 BERT。

1. **BERT 预训练语言模型** BERT 双向 Transformer 结构可以充分利用上下文信息，捕捉词语在当前句子中的语境含义。经过微调之后，充分适配本新闻多分类任务，Accuracy 与 Macro-F1 均显著高于传统词向量、词袋模型，是本次实验效果最好的模型。
2. 数据集不平衡说明 NYT 数据集 sports 样本数量远大于 business、politics，单纯看 Accuracy 容易高估模型对少数类的能力，因此采用 **Macro-F1** 作为核心评估指标，对三个类别同等权重评估，结果更加客观。

七、实验总结

1. 传统词袋模型实现简单，计算速度快，但缺少语义理解能力，分类效果存在上限。
2. 分布式词向量（Word2Vec、GloVe）得到稠密语义表示，性能优于 BoW；词向量训练语料域和下游任务匹配度会直接影响分类效果，同任务语料训练得到的词向量效果优于域外语料。
3. BERT 预训练模型依靠强大双向上下文建模能力，在新闻文本分类任务取得最优效果，但 BERT 微调对硬件 GPU 有一定要求，训练耗时比传统机器学习方法更长。
4. 多分类不平衡数据集，不能只依赖准确率，Macro-F1 可以更公平评估每一类分类效果。